

Check-IA – Note méthodologique de l'évaluation

Version 1 · Juillet 2026

OBJET

Cette note décrit la méthode et les résultats de la première évaluation systématique de Check-IA, la plateforme de vérification d'informations pour l'espace sahélien. L'évaluation porte sur la vérification de textes en français, mesurée sur le système tel qu'il est en production.

CORPUS

396 affirmations réelles ont été constituées à partir de vérifications publiées entre 2019 et 2026 par deux organisations de fact-checking maliennes indépendantes : **Benbere** (#BenbereVerif) et **Voix de Mopti** (Mopti Check). Chaque affirmation a été reformulée sous la forme neutre qu'un utilisateur soumettrait (sans vocabulaire de verdict), avec vérification humaine par échantillonnage de la fidélité des reformulations. 371 affirmations ont un verdict de référence strictement **vrai ou faux** ; les 25 restantes relèvent de catégories nuancées (**trompeur, hors contexte**) et sont mesurées à part.

VÉRITÉ DE RÉFÉRENCE

Le verdict de référence de chaque affirmation est ancré dans la conclusion publiée par le fact-checkeur d'origine. Parce que la réalité évolue – certaines affirmations fausses au moment de leur vérification se sont réalisées ensuite – l'ensemble du corpus a fait l'objet d'un audit temporel : chaque affirmation susceptible d'avoir changé de statut a été re-vérifiée au regard des événements survenus jusqu'en juillet 2026, sources à l'appui, et les verdicts de référence ont été mis à jour en conséquence. Les fact-checkeurs cités sont les auteurs des vérifications d'origine ; ils n'ont ni supervisé ni approuvé cette évaluation.

PROTOCOLE

Chaque affirmation a été soumise au système de vérification en production, dans les mêmes conditions qu'une soumission d'utilisateur. Les verdicts rendus ont été comparés aux verdicts de référence. Un sous-ensemble a également été soumis via l'application déployée de bout en bout afin de mesurer les temps de réponse réels.

MÉTRIQUES PUBLIÉES

- **Verdict correct / prudence / verdict erroné** : répartition des issues sur les 371 affirmations vrai/faux. La « prudence » désigne les cas où le système choisit de ne pas trancher plutôt que de deviner.
- **Exactitude des verdicts tranchés** : proportion de verdicts corrects parmi les affirmations où le système a tranché.
- **Fausse information validée à tort** : proportion d'affirmations fausses auxquelles le système a attribué un verdict « vrai » – l'erreur la plus grave pour un outil de vérification.
- **Temps de réponse médian** : mesuré de bout en bout sur l'application déployée.

RÉSULTATS (V1 – JUILLET 2026)

Mesure	Résultat
Verdict correct	72,8 % (270/371)
Prudence (pas de verdict)	24,3 % (90/371)
Verdict erroné	3,0 % (11/371)
Exactitude des verdicts tranchés	96,1 % (270/281)
Fausse information validée à tort	1,7 % (6/355)
Temps de réponse médian	≈ 30 secondes

Sur les 25 affirmations nuancées (trompeur, hors contexte), le système conclut « faux » dans 60 % des cas – un rapprochement acceptable pour un système à trois verdicts, mesuré séparément pour ne pas altérer les chiffres principaux.

LIMITES

- Le corpus est majoritairement composé d'affirmations fausses (355 sur 371), à l'image des publications de fact-checking dont il est issu. Les mesures relatives aux affirmations vraies reposent sur un effectif réduit et sont indicatives.
- Les affirmations portant sur l'identité d'images ou de vidéos (« cette photo montre... ») ont des limites propres lorsqu'elles sont évaluées par la voie textuelle.
- Les résultats reflètent l'état du système et du web en juillet 2026.

VERSIONS

Les évaluations sont datées et versionnées. Les résultats des évaluations suivantes seront publiés sous les versions v2, v3, ... sur la page [Fiabilité de check-ia.app](#).